Comment prédire la consommation électrique

Les modèles XGBoost, LightGBM et CatBoost, expliqués simplement

Projet S9 POWER · encadrants : E. Grivel, A. Leys

1 **Notre projet**
ce que nous cherchons à prédire, et pourquoi cette méthode

2 **Les bases**
l'arbre de décision, puis le boosting : des arbres qui se corrigent

3 **Trois modèles**
XGBoost, LightGBM, CatBoost : leur nom, leur intérêt, leur rôle chez nous

4 **Les comparer**
notre méthode d'expérience

Notre projet et nos données

POWER : prévoir la consommation électrique française, heure par heure.

Peut-on prévoir ce que la France va consommer demain ?

Pourquoi : l'électricité ne se stocke pas

Repère : prévision de RTE, $\approx$ 2 % d'erreur

Exemple : 12 oct. 2026, 16 h · 46 648 MW réels · 45 800 MW prévus par RTE

Indicateurs : connus à l'avance				Cible
Date et heure	Jour	Temp.	Férié	Conso (MW)
14 janv. 2025, 03:00	mardi	1 °C	non	**56 200**
14 janv. 2025, 19:00	mardi	2 °C	non	**78 100**
19 janv. 2025, 19:00	dimanche	4 °C	non	**66 300**
15 août 2025, 13:00	vendredi	28 °C	oui	**36 500**
…	…	…	…	…

Valeurs illustratives · 1 ligne = 1 heure

1 Collecter — consommation, météo, calendrier › **2 Assembler** — une table : 1 ligne = 1 heure › **3 Entraîner** — le modèle apprend sur le passé › **4 Prédire** — une année jamais vue › **5 Comparer** — à la réalité et à RTE

Entraîner = montrer des milliers d'exemples dont on connaît déjà la réponse

Les indicateurs ajoutés : calendrier et météo

Une seule table · 1 ligne = 1 heure (repérée en UTC) · 2019 → 2025 · environ 61 000 lignes

Calendrier

Fichier du groupe (1 ligne par jour), recopié sur les 24 heures du jour.

jour, mois, saison	mardi, janvier
week-end, jour ouvré	oui / non
jour férié	oui / non
vacances scolaires	zones A, B, C
Noël, saison de chauffage	oui / non

Météo

Météo-France, 12 stations (1 par région), moyenne France pondérée par la population.

température	2 °C
rayonnement solaire	350 W/m²
ensoleillement	40 min / h
vent	4 m/s
humidité, pluie	85 %, 0,2 mm

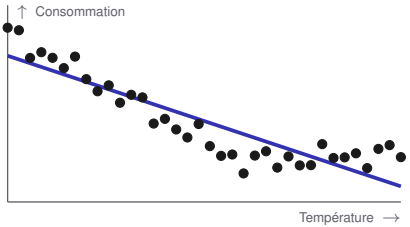
À retenir

Températures **mesurées**, pas prévues : le score sera un peu optimiste. Calendrier à étendre à 2019 – 2022.

Pourquoi cette méthode, et pas une autre ?

Plus il fait froid, plus on chauffe, puis la courbe devient plate.

Consommation selon la température



En bleu : une droite. Elle se trompe presque partout.

Les autres pistes

Régression linéaire

Idée : une droite

Limite : courbe coudée ratée

Séries temporelles (ARIMA)

Idée : prolonger une courbe qui se répète

Limite : peu adapté à la météo

Réseaux de neurones (LSTM)

Idée : un « cerveau artificiel »

Limite : gourmand en données, peu explicable

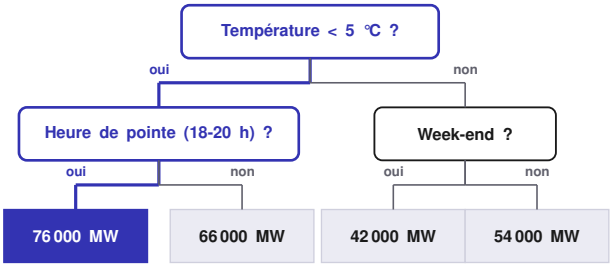
Notre choix

Arbres de décision + boosting : suivent les courbes, mélangent heure, météo, calendrier, restent explicables.

L'arbre de décision : un jeu de questions

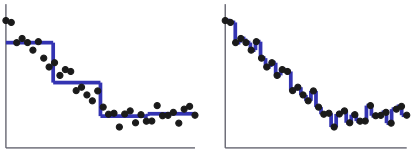
Une suite de questions oui / non, puis une prédiction.

Exemple : mardi, 19 h, 2 °C



Chemin en bleu : 2 °C, 19 h → 76 000 MW (chiffres illustratifs).

Comment il apprend : il découpe



4 groupes ✓ : suit la forme

30 groupes × : par cœur

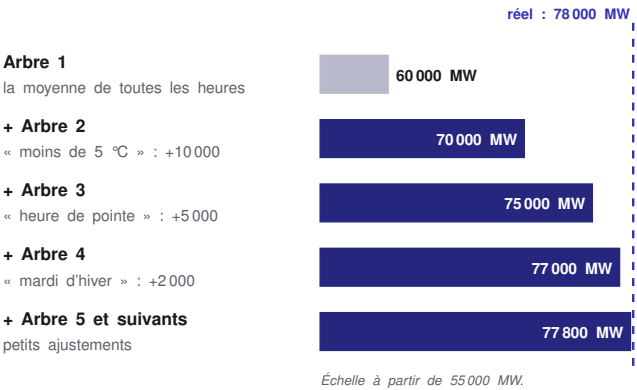
Chaque feuille : moyenne des cas passés semblables.

Un seul arbre ne suffit pas

Trop simple, ou par cœur. L'idée du boosting : en combiner beaucoup de petits.

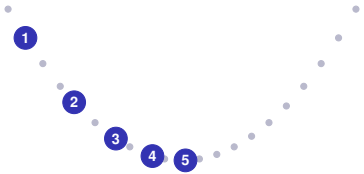
Le boosting : des arbres qui se corrigent

Un mardi à 19 h par grand froid : 78 000 MW réels (chiffres illustratifs).



Échelle à partir de 55 000 MW.

Pourquoi « gradient » ? La pente



Chaque numéro = un arbre = un pas vers le bas.

Gradient = la pente
Learning rate = taille du pas
Nombre d'arbres = nombre de pas

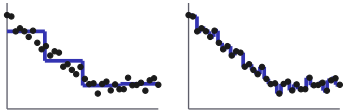
Chaque arbre corrige le reste

Un arbre = faible · quelques centaines = très précis. To boost = renforcer.

XGBoost : le boosting « extrême »

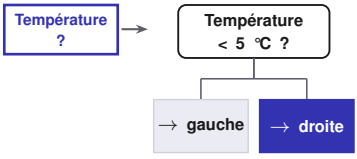
eXtreme Gradient Boosting · créé en 2014 par Tianqi Chen · « extrême » : pousser le boosting à ses limites.

1. Il évite d'apprendre par cœur



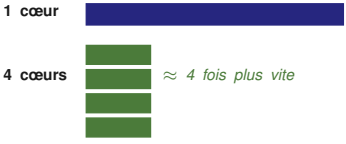
Pénalité sur les arbres trop compliqués : il comprend, il ne récite pas.

2. Il gère les valeurs manquantes



Mesure absente : le modèle sait où envoyer les trous.

3. Il calcule en parallèle



Arbre construit sur plusieurs cœurs à la fois : bien plus rapide.

En bref

Même logique que le boosting classique, en plus fiable et plus rapide.

XGBoost dans notre projet

Notre modèle de référence : solide et très répandu.

Ce qu'on lui donne

Que des nombres : les mots sont transformés.

lundi	mardi	mercredi	jeudi	vendredi	samedi	dimanche
1	2	3	4	5	6	7

Exemple (valeurs illustratives)

Mardi 14 janvier 2025 · 19 h · 2 °C · non férié

XGBoost prédit
77 200 MW

réel : 78 100 MW
erreur : 1,2 %

Les 4 étapes

1. Charger 2012 → 2023.
2. Régler : nombre d'arbres, profondeur, learning rate.
3. Entraîner : arbres ajoutés un à un.
4. Prédire 2024 · mesurer l'erreur (MAPE) · comparer à RTE.

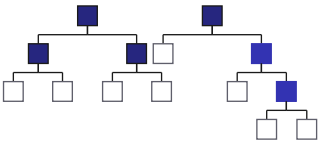
Son rôle chez nous

La référence, mêmes données et mêmes découpages que les autres modèles.

LightGBM : le boosting « léger »

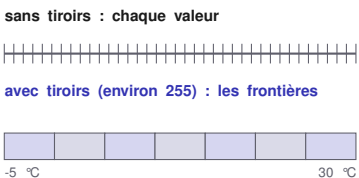
Light Gradient Boosting Machine · Microsoft, 2016 · « light » = rapide et léger

1. Il coupe feuille par feuille



Il ne creuse que la feuille où l'erreur est la plus forte.

2. Il range les valeurs en tiroirs



Peu de seuils à tester : bien plus rapide.

3. Il se concentre sur ses erreurs



GOSS : il apprend surtout sur ce qu'il rate encore.

En bref

Même logique que XGBoost, mais un entraînement nettement plus rapide et moins gourmand en mémoire.

LightGBM dans notre projet

Notre modèle pour tester vite et donner une fourchette.

1. Tester les indicateurs

Base : heure, jour, mois

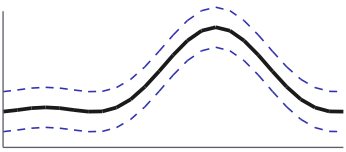
\+ température

\+ jours fériés

\+ vacances

On garde un indicateur s'il fait baisser l'erreur sur 2024.

2. Une fourchette de valeurs



Quantiles 10 et 90 % : « entre 70 000 et 80 000 MW ».

3. Ses pièges

! Trop de feuilles : par cœur

! Record de froid : sous-estimé

! Importance : lire le gain

Parade : arrêt anticipé sur 2024.

Son rôle chez nous

Explorer vite les indicateurs, et donner des fourchettes au tableau de bord.

CatBoost : le boosting des catégories

Categorical Boosting · « cat » = catégorie (pas un chat) · Yandex, 2017

1. Il lit directement les catégories

Sans : 7 colonnes 0 / 1

1	0	0	0	0	0	0
0	**1**	0	0	0	0	0
0	0	**1**	0	0	0	0

lun · mar · mer…

Avec : des mots

lundi
mardi
…

Jour, mois, zone : lus tels quels, sans passer en nombres.

2. Il évite de tricher

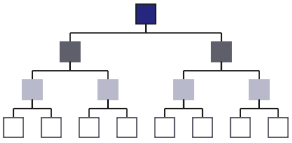
1	2	3	4	5	6

utilisées **à prédire** pas vue

Pour la ligne 5, il n'utilise que les lignes 1 à 4.

Une ligne n'est jamais corrigée par un modèle qui l'a déjà vue.

3. Des arbres symétriques



même question sur tout un étage

Même question à chaque étage : prédiction très rapide.

En bref

Peu de réglages ; entraînement souvent plus lent que LightGBM.

CatBoost dans notre projet

Notre modèle pour les variables qui sont des mots.

Nos colonnes : nombres ou catégories ?

heure	nombre	19
jour de la semaine	catégorie	mardi
mois	catégorie	janvier
férié	catégorie	oui / non
zone de vacances	catégorie	A, B ou C
température	nombre	2 °C
consommation 7 jours avant	nombre	74 500 MW

Valeurs d'exemple illustratives.

Comment on l'utilise

On indique les colonnes catégorielles :

```
cat_features = [jour, mois, férié, zone]
```

- Mots lus tels quels.
- Bon résultat sans long réglage.
- Plus lent à entraîner.

Son rôle chez nous

Tester jour, mois et vacances comme de vraies catégories.

Comparaison et méthode

	XGBoost	LightGBM	CatBoost
Son nom	eXtreme Gradient Boosting	Light Gradient Boosting Machine	Categorical Boosting
Créé	2014 · Tianqi Chen	2016 · Microsoft	2017 · Yandex
Spécialité	Fiabilité · gère les trous	Vitesse · mémoire	Catégories · ordered boosting
Arbres	Niveau par niveau	Feuille par feuille	Symétriques
À surveiller	Mots → nombres	Par-cœur si trop de feuilles	Entraînement plus lent
Chez nous	**Modèle de référence**	**Exploration rapide, fourchettes**	**Jour, mois, vacances en catégories**

Même parcours pour les trois : un indicateur à la fois · on garde si l'erreur baisse (2024) · test unique sur 2025

Base : heure, jour, mois › + température › + jours fériés › + vacances › + valeurs passées



Notre base de données

Une seule table horaire, la même pour les trois modèles et pour tout le groupe.

Ce qu'elle contient

122 736 heures
du 1er janv. 2012 au 31 déc. 2025

1 ligne = 1 heure
repérée en heure UTC

14 heures vides
1 par an : passage à l'heure d'hiver

Comment elle est construite : 3 scripts Python

01 Télécharger
RTE éCO2mix définitif (ODRÉ)
1 valeur / 30 min

→

02 Construire
moyenne par heure
retire les fausses heures de mars

→

03 Charger
PostgreSQL (Neon) en ligne, relançable sans doublon

Piège des changements d'heure. En mars, RTE ajoute une heure 2 h qui n'existe pas, avec des valeurs recopiées : retirée. En octobre, l'heure en double n'est publiée qu'une fois : il manque 1 heure par an, laissée vide pour le nettoyage. En UTC, il y a toujours exactement 1 h entre deux lignes.

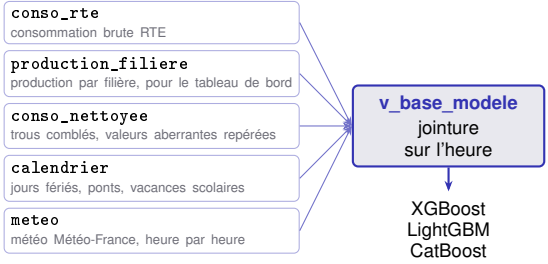
Le principe

Les données RTE sont gardées brutes, seulement mises au pas horaire : rien n'est corrigé ici. On garde aussi la prévision de la veille de RTE, la référence que nos modèles devront battre.

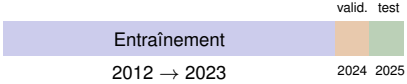
Comment la base sert au projet

Une table par source de données ; une vue assemble tout, heure par heure, pour les modèles.

Une table par source, une vue pour tout réunir



Le même découpage pour tous



105 192 h pour apprendre, 8 784 h pour régler, 8 760 h pour le verdict final.

Les règles de la base

– Rien d'inconnu la veille : conso passée d'au moins 48 h.

– Météo mesurée : score un peu optimiste, on le signalera.

– Production par filière : tableau de bord seulement.

Notre vision du projet

Une seule source pour tout le groupe : mêmes heures, même découpage, donc des scores comparables. À partir de ces tables, on construit maintenant les variables des modèles.